

## 9. VE (2)

### 6 Fuzzy Systeme

#### 6.1 Fuzzy Logic

(„behandelt Ungenauigkeit der Sensoren“)

##### (Scharfe) Menge

geg.: Grundmenge  $G$

Menge  $M \subseteq G$  durch Zugehörigkeitsfunktion

$$\forall x \in G: m_M(x) = \begin{cases} 1 & \text{falls } x \in M \\ 0 & \text{sonst} \end{cases}$$

##### Unscharfe Menge (Fuzzy Set)

Zugehörigkeitsfunktion:  $\forall x \in G: x \rightarrow m_M(x) \in [0, 1]$

Je größer  $m_M(x)$  ist, umso mehr ist  $x$  in  $M$  enthalten

Gewöhnliche Mengen sind spezielle unscharfe Mengen mit eingeschränktem Wertebereich der Zugehörigkeitsfunktion

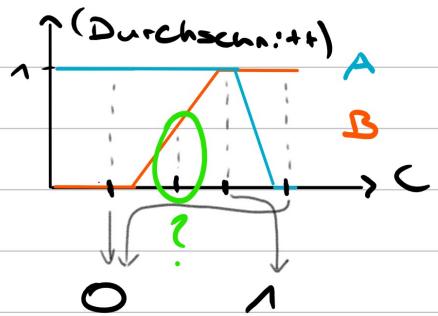
#### Beispiel: Zulässige Spannungswerte Fahrzeug mit klassischen Bordnetz

##### Fuzzy Set mit Zugehörigkeitsfunktion



## Mengenoperationen

geg: Fuzzy Sets  $A, B \subseteq G$

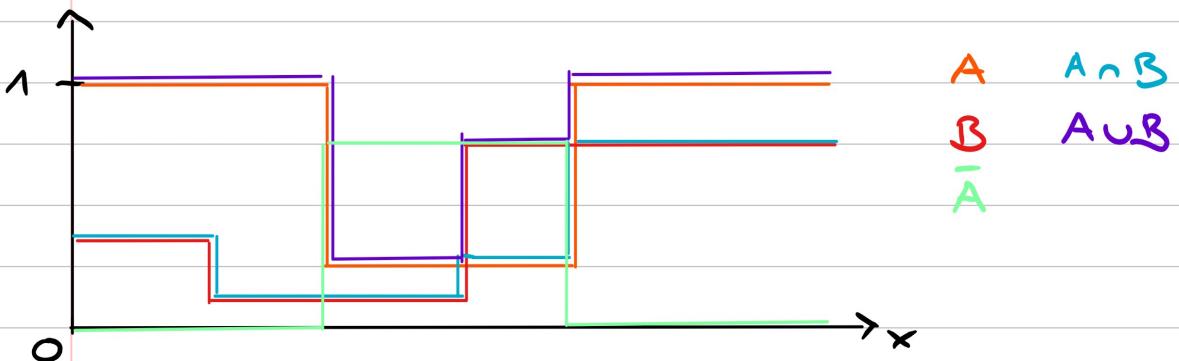


$$m_C(x) =$$

- Durchschnitt:  $C = A \cap B: m_C(x) = \min(m_A(x), m_B(x)), \forall x \in G$
- Vereinigung:  $C = A \cup B: m_C(x) = \max(m_A(x), m_B(x)), \forall x \in G$
- Komplement:  $C = \bar{A}: m_C(x) = 1 - m_A(x), \forall x \in G$

10. VE

## Beispiel



## Logikoperationen

geg.: Fuzzy Sets  $A, B \subseteq G, \gamma \in [0; 1]$

Fuzzy AND

Skalierung (mehr Durchschnitt? oder arithm. Mittel?)

$$C = A \wedge B: m_C(x) = \underbrace{\gamma \cdot \min\{m_A(x), m_B(x)\}}_{\text{Durchschnitt}} + (1-\gamma) \cdot \underbrace{\frac{1}{2} (m_A(x) + m_B(x))}_{\text{arithmetisches Mittel}}, \forall x \in G$$

## • Fuzzy OR

$$C = A \vee B : m_C(x) = \underbrace{\gamma \cdot \max\{m_A(x), m_B(x)\}}_{\text{Vereinigung}} + (1-\gamma) \cdot \underbrace{\frac{1}{2} (m_A(x) + m_B(x))}_{\text{arithmetisches Mittel}}, \forall x \in G$$

$\gamma$  für Skalierung (Konfigurationsparameter)

$\gamma = 0$  : arithmetisches Mittel für beide Logikoperatoren

$\gamma = 1$  : Durchschnitt bzw. Vereinigung  $\Rightarrow$  hier Fuzzy Regler

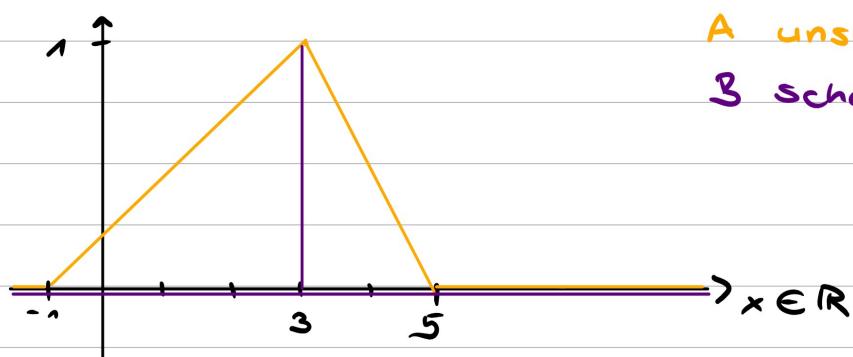
$\gamma < 1$  : Weiche Constraints  $\Rightarrow$  intelligente Roboter (KIM)

Eine unscharfe Zahl ist eine unscharfe Menge (Fuzzy Set)  $A \subseteq \mathbb{R}$ :

- $\exists a \in \mathbb{R} : m_A(a) = 1$
- $m_A(x)$  ist wenigstens stückweise stetig

Beispiel: Fuzzy Sets A und B

$$m_A(x) = \begin{cases} \frac{1+x}{4} & \text{für } x \in [1; 3] \\ \frac{5-x}{2} & \text{für } x \in [3; 5] \\ 0 & \text{sonst} \end{cases} \quad m_B(x) = \begin{cases} 1 & \text{für } x = 3 \\ 0 & \text{sonst} \end{cases}$$



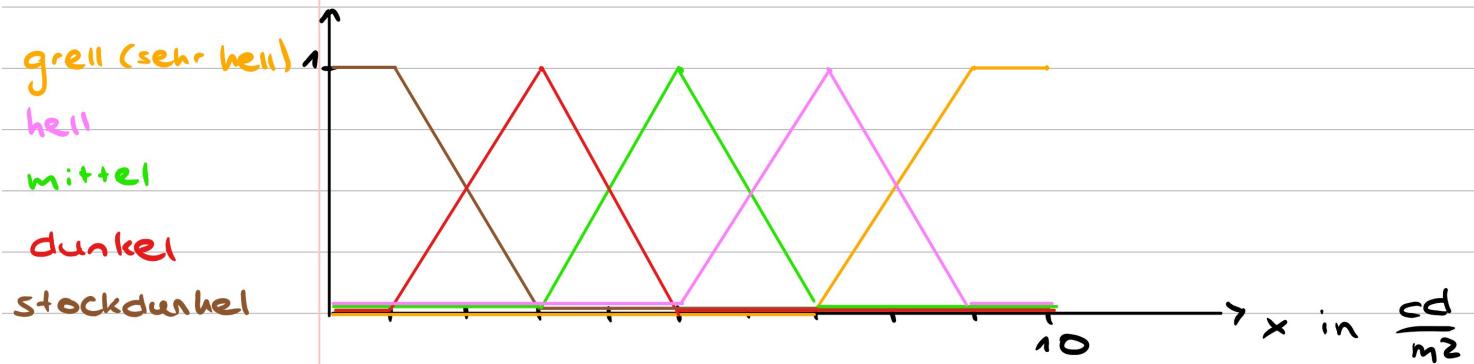
A unscharf Zahl 3

B scharfe Zahl 3

## Anwendung unscharfer Zahlen:

- Ungenauigkeit in Sensormesswerten
- Unscharfe Formulierungen in Vergleichen mit linguistischen Variablen und Werten

### Beispiel: Linguistische Variable Helligkeit



cd - Candela (Einheit der Lichtstärke)

## 6.2 Fuzzy Regler

Komplexe Steuerungs- und Regelungsprobleme ohne hinreichendes mathematisches Modell

Prinzip: Programmierung des Reglerverhaltens durch Fuzzy Regeln in folgender Form:

if <Bedingung> then <Aktionen>

<Bedingung>: Verknüpfung von Einzelbedingungen über Sensordaten mit Fuzzy Operatoren

<Aktionen>: Vorgaben für Autoren

Angabe der Einzelbedingungen und Aktion mit linguistischen Variablen

## Beispiel: ACC

### Bedingung

if (Geschwindigkeit = schnell AND Abstand = nah)  
then Bremsleistung = langsamer } Aktion

linguistische Variablen

linguistische Werte

Einzelbedingung

### Interferenzmechanismus (Handout)

Auswertung der Regelmenge, hier: Min-Max-Methode

### ↳ Interferenzmethode Fuzzy-Regler

11. VE

### Min-Max-Methode

Zyklische Ausführung folgender Schritte:

- \* Umwandlung Sensordaten in unscharfe Zahlen gemäß Sensorqualität (Fuzzifikation) von 1 auf 1
- \* Prüfung Bedingung der Regeln: Ausführung der Aktionen entsprechend dem Erfüllungsgrad der Regelbedingung. Erfüllungsgrad entspricht der Höhe des Fuzzy Sets aus der Überlappung der Fuzzy Set von linguistischer Variable und unscharfen Messwert
- \* Verknüpfung Höhen Einzelbedingung gemäß Logikoperator
- \* Reduktion Fuzzy Sets der Aktionen entsprechend Verknüpfungsergebnis
- \* Vereinigung der reduzierten Fuzzy Sets zu je einem Fuzzy Set für jede Stellgröße
- \* Transformation der Fuzzy Sets der Stellgrößen zu einem konkreten Stellwert für jede Größe (Defuzzifikation)

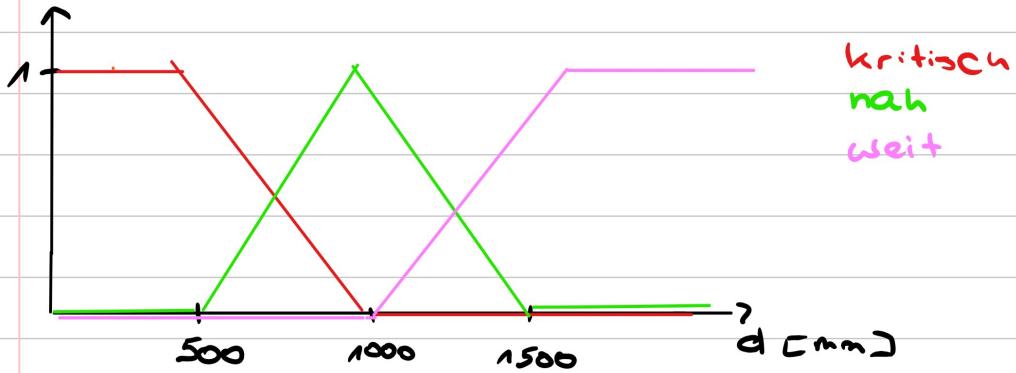
## Wichtige Methoden Defuzzifikation:

- \* Auswahl absolutes Maximum, z.B. von links nach rechts (Sicherheitsstellung)
- \* Bildung Mittelwert aller Maxima
- \* Schwerpunktbildung  $x_{res} = \frac{M}{I}$ , Moment  $M = \int x \cdot f(x) dx$ , Fläche  $F = \int f(x) dx$

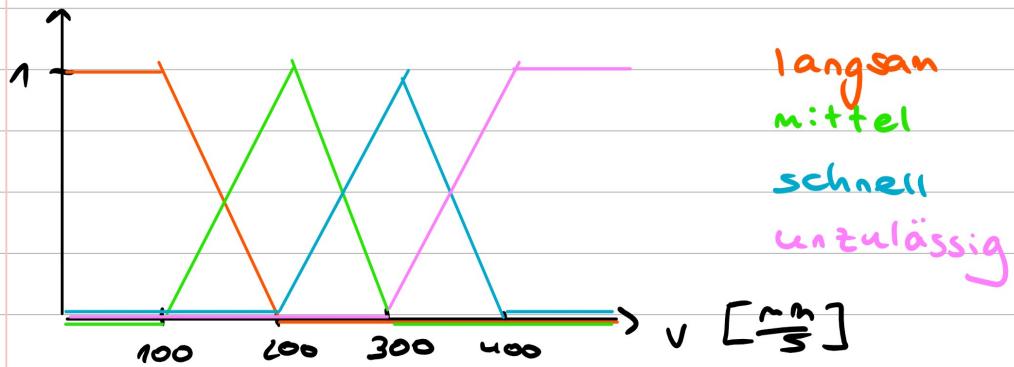
Beispiel: (Handout für 230  $\frac{m}{s}$  und 80cm)

↳ vereinfachtes ACC (für Laborroboter)

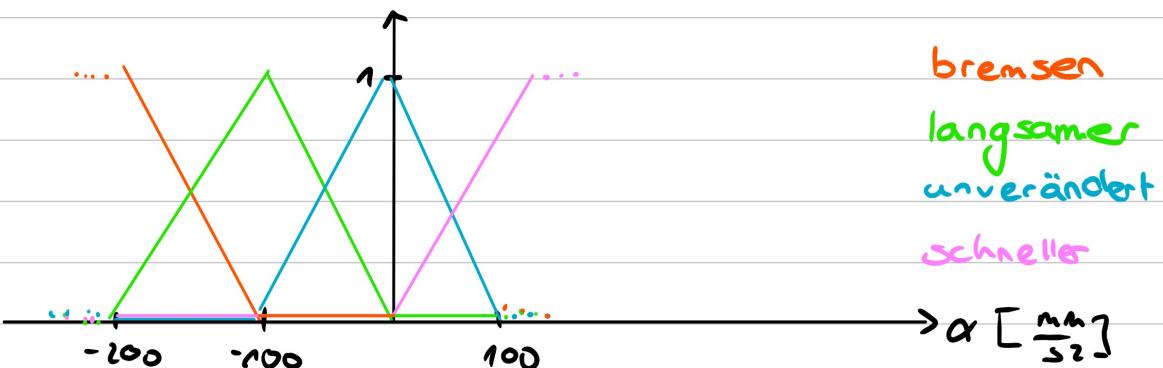
### Abstand



### Geschwindigkeit



### Beschleunigung



Beschleunigung	Geschwindigkeit			
	unzulässig	schnell	mittel	langsam
weit	bremsen	unverändert	schneller	schneller
Abstand				
nah	bremsen	langsamer	unverändert	unverändert
kritisch	bremsen	bremsen	bremsen	bremsen

Stellglied wertet negative Geschwindigkeiten zu 0.

## 12. VE

### 7 Umweltmodellierung

Repräsentation des Wissens über die Umwelt im LPS

#### 7.1 Kartographie

Zunächst Kartenbildung mit Laserscans. Später Erweiterung um Bildinformationen.

Im ersten Schritt: Filterung der Laserdaten

- Medianfilter: Ersetzung Ausreißer im Scan durch geeignete Messwerte. Legen Fenster um Ausreißer, Ersetzung Ausreißer durch Median im Fenster

## Beispiel:

Laserscan ... 1,0

1,2	1,3	2,2	1,4	1,4	1,5..
-----	-----	-----	-----	-----	-------

Auflösererkennung über maximale Wertänderung

Korrekturwert Median: 1,2 1,3 1,4 1,4 2,2

Median

- Reduktionsfilter: sukzessive Zusammenfassung von Punktwolken zu einem Punkt (Schwerpunkt) im Kreis um nächstgelegenen Punkt

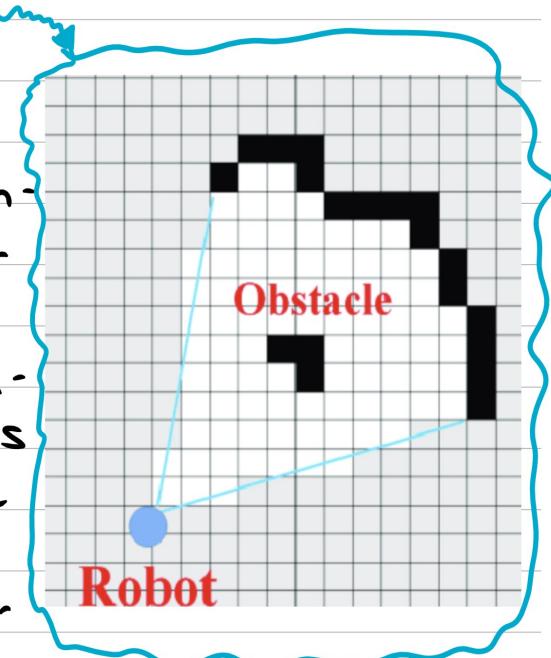


## Fusion der Datenströme

- Kalman-Filter (-> Signalverarbeitung)

- Occupancy-Grid (-> hier)

↳ Segmentierung Umfeld in Gitter, Eintragung Sensorsmesswerte in Gitterzellen, bei hinreichend vielen Eintragungen in einer Zelle wird Zelle als belegt markiert. Größe Gitterzellen frei wählbar und richtet sich nach Größe zu erwartender Umfeldobjekte



### Beispiel:

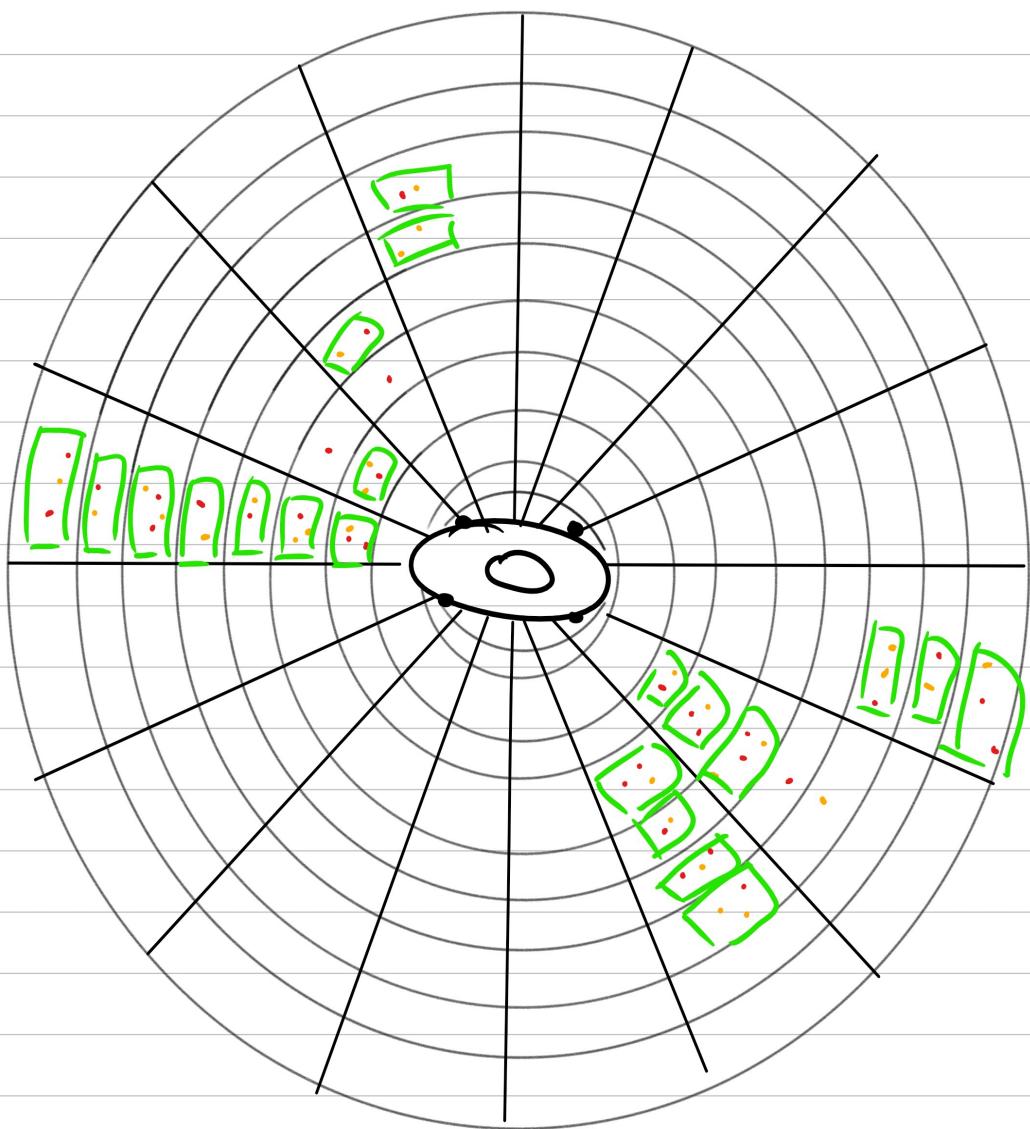
Fahrzeug mit 2 Entfernungssensoren, kreisförmige Gitter mit zunehmende Gitterradien

Sensor 1

Sensor 2

Fusion mind. 2

Gittereinträge



Bei exakten Sensoren hinreichend wenn ein Sensor die Belegung erkennt.

Bei unsicheren Sensoren werden Unsicherheiten in den Messwerten durch Wahrscheinlichkeiten ausgedrückt.

Berechnung Belegheitswahrscheinlichkeit über Evidenztheorie (Dempster-Shafer-Theorie).

Versaligemeinerung Satz von Bayes

Geg. Meng  $E$  sich gegenseitig ausschließender Ereignisse  
 $\Theta$  (Wahrnehmungsrahmen)

Massefunktion  $m: 2^\Theta \rightarrow [0, 1]$  mit  $m(\emptyset) = 0$   
 und  $\sum_{x \in 2^\Theta} m(x) = 1$

ordnet jedem Ereignis eine Wahrscheinlichkeit zu.

$$m_1 \oplus m_2 (x) := \begin{cases} \frac{\sum_{A_i \cap B_j = x} m_1(A_i) \cdot m_2(B_j)}{1 - \sum_{A_i \cap B_j \neq \emptyset} m_1(A_i) \cdot m_2(B_j)} & x \neq \emptyset \\ 0 & x = \emptyset \end{cases}$$

⊕ ist kommutativ und assoziativ

Anpassung ⊕ auf Datafusion mit 2 Sensoren

$\Theta = \{B, B'\}$  mit  $B$  zelle belegt erkannt,  $B'$  zelle frei erkannt

$$2^\Theta = \{\emptyset, \{B\}, \{B'\}, \Theta\}$$

$$m_1 \oplus m_2 (\{B\}) := \frac{m_1(B)m_2(B) + m_1(\emptyset)m_2(\emptyset) + m_1(B)m_2(\emptyset)}{1 - m_1(B)m_2(B) - m_2(B)m_1(B)}$$

$m(\emptyset)$ : Unschlüssigkeit Belegungsmessung, bei exakten Sensoren

## Beispiel

Geg: Messungen von Radar und Laserscanner bezogen auf eine Gitterzelle

$$m_{\text{Radar}}(\beta) = 0,6$$

$$m_{\text{Radar}}(\theta) = 0,2$$

$$m_{\text{Laser}}(\beta) = 0,7$$

$$m_{\text{Laser}}(\theta) = 0,1$$

$$m_{\text{Radar} \oplus \text{Laser}}(\beta) = \frac{0,6 \cdot 0,7 + 0,2 \cdot 0,7 + 0,6 \cdot 0,1}{1 - 0,2 \cdot 0,7 - 0,1 \cdot 0,6}$$

$$\hookrightarrow 1 - (0,6 + 0,2) \quad \hookrightarrow 1 - (0,7 + 0,1)$$

$$= 0,83$$

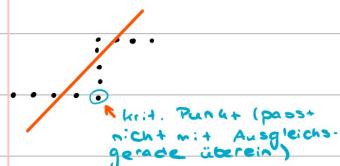
Extraktion von Merkmalen (Linien, Ecken, Objekte etc.) am Occupancy Grid.

Speicherung in semantischen Karte.

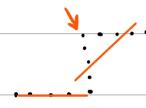
Extraktion von Linien mit Divide-And-Conquer-Algorithmus (Gutmann).

Geg. Scans:

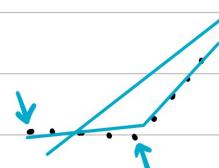
1. Schritt: Ausgleichsgerade



2. Schritt: Aufteilen und Rekursion



3. Schritt: Terminierung



## Erkennung -> Literatur

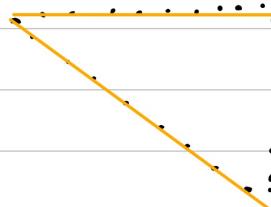
Alternative zu Divide-And-Conquer: Umwandlung Occupancy Grid in Pixelbild mit Verwendung von Bildfiltern zur Kantenextraktion.

Bildfilter: Sobel-Operator und Hough-Transformation

Ergebnis Sobel:  
(Faltung) .:..... .:.....

.:..... .:.....

Hough-Transformation:  
(Nachverfolgungs-Chipping)



Kantenerkennung über Region Growing (Blobs) möglich.  
Die fusionierten Objekte werden anschließend zu Objekten klassifiziert.

Matching gelernter Kantenbilder: Einsatz wissenbasierter Algorithmen mit folgender KI-Technik:

- Neuronale Netze } Literatur
- Produktionsregeln
- Und / Oder - Graph mit Taxonomie => hier

## Klassifikation mit Taxonomie

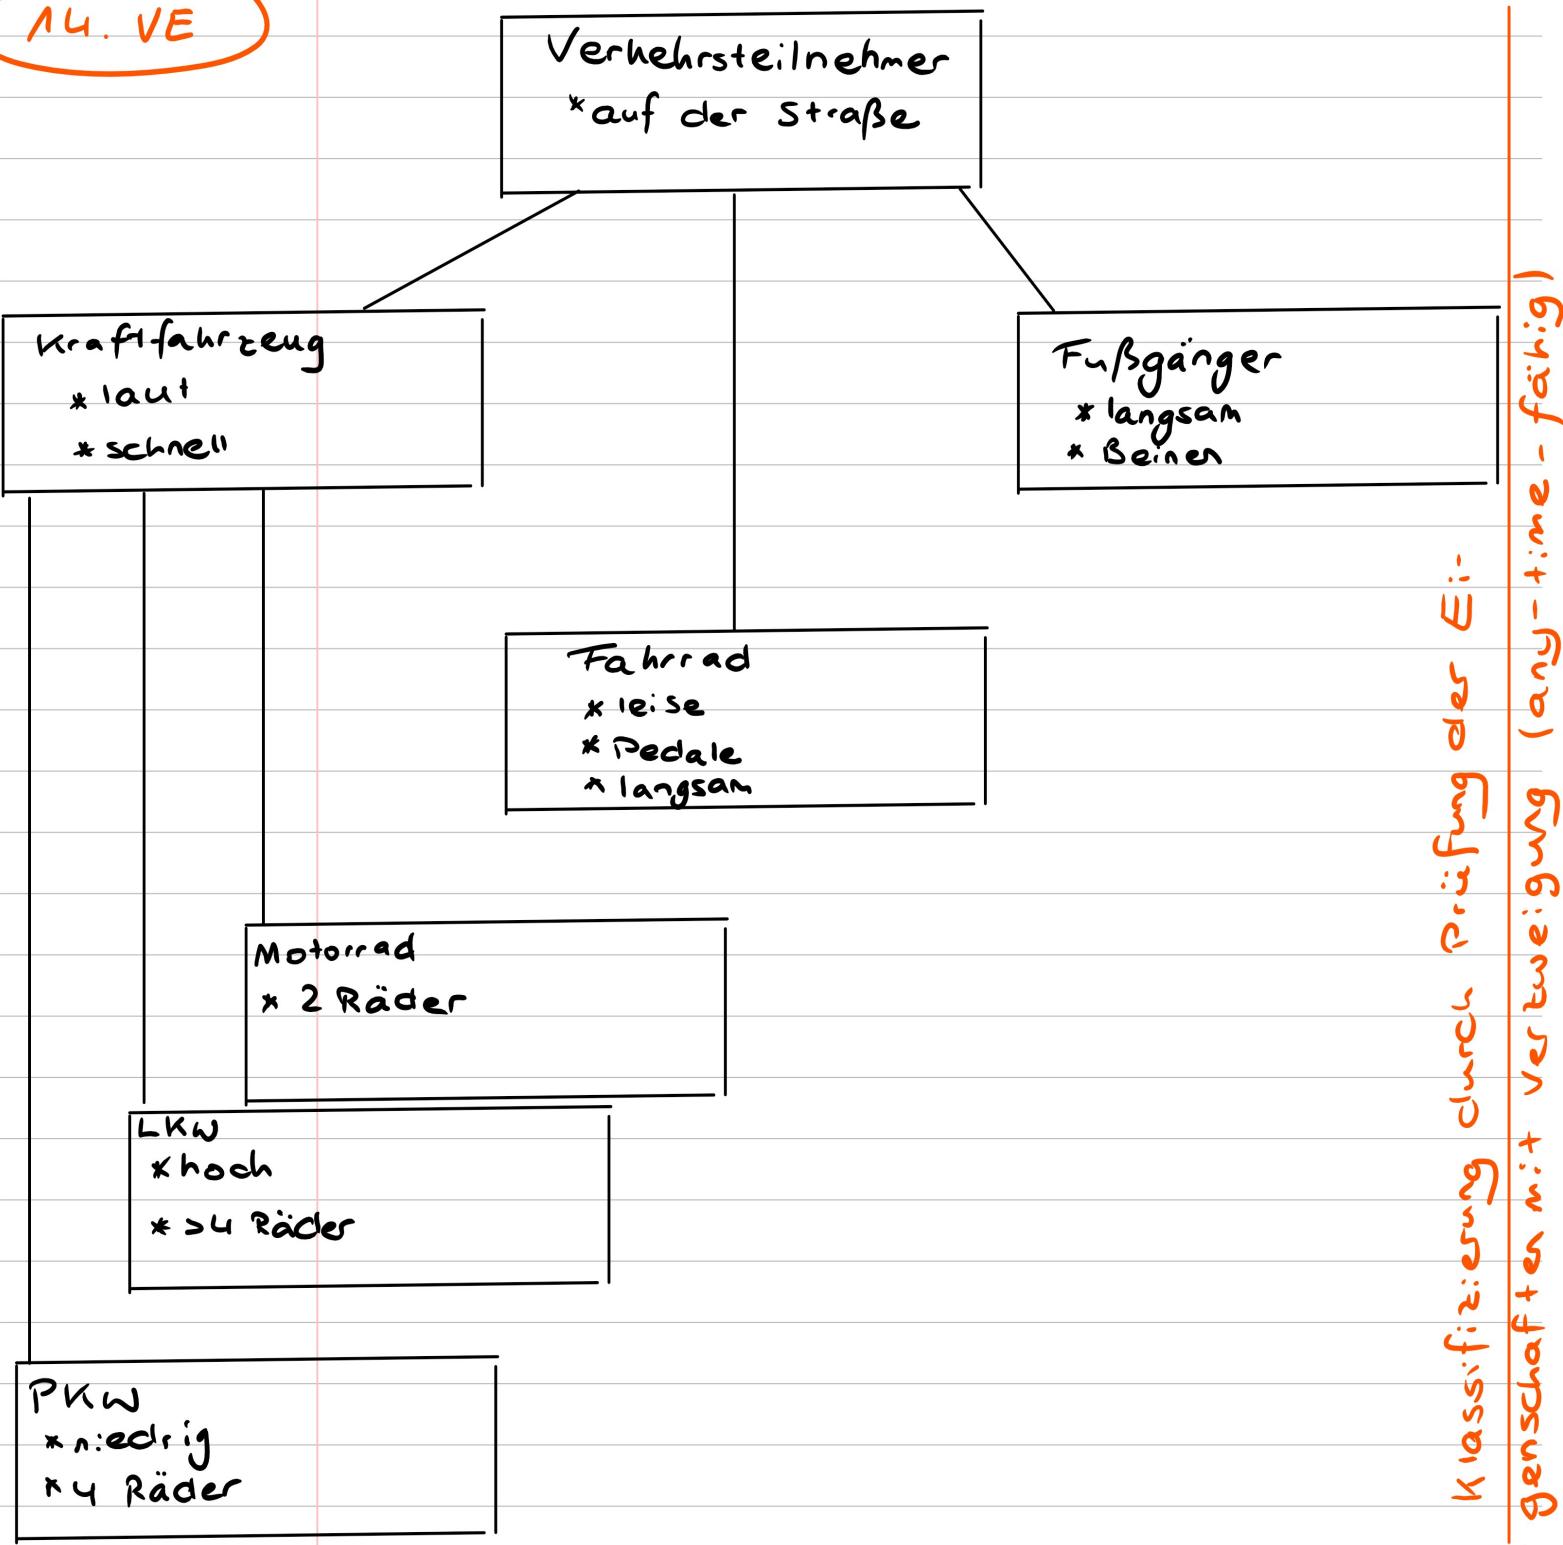
Anordnung der gelernten Objekte mit ihren Merkmalen in einer Objekt hierarchie mit Verwendung :St-ein-Relation von unter- zur Oberklasse (Taxonomie)

Bei Klassifikation wird Taxonomie von Wurzel her durchlaufen. Verzweigung anhand Merkmalsübereinstimmung

## Beispiel: nächstes Mal

Klassifizierte Objekte werden danach zu einer Szene in Bezug gesetzt (Szenengraph!)

14. VE



Klassifizierung durch Prüfung der Eigenschaften mit Verzweigung (any-time-fähig)

## 7.2 Selbstlokalisierung

Ziel: Bestimmung Fahrzeugposition in Karte anhand aktueller Sensordaten

Hier: Laserscanner als Sensor (SLAM)

Formale Aufgabe:

Geg.: Scan  $t$  (Referenzscan der Karte)  
Scan  $s$  (Aktuell aufgenommener Scan)

Ges.: L Lokalität des Fahrzeugs in Karte  
 $\text{match}(l) \rightarrow p(l) \in [0; 1]$   
 $p(l)$  ist umso größer, je besser sich  $s$  mit  $t$  nach bester Verschiebung und Drehung überdeckt

Die Berechnung von  $\text{match}$  ist ein Suchproblem mit Mehrdimensionalem Raum.

Vereinfachung Suchproblem durch Annahmen.

\* Gauß-Verteilung

Approximation durch Gauß-Funktion, Verwendung von Erwartungswert und Varianz

\* Lokalitätsannahme

Ungefährre Position von  $s$  im Koordinatensystem von  $t$ , z.B. durch GNSS oder Odometriiedaten

Damit scan-match als neue Funktion mit  
 $\text{scan-match}(s, t) = (\mu_{\text{match}}, \Sigma_{\text{match}})$

$\mu_{\text{match}} = \begin{pmatrix} x_1 \\ y_1 \\ 0 \end{pmatrix}$  Erwartungswert  $\Rightarrow$  Lokalität des Fahrzeugs

$\Sigma_{\text{match}} = \begin{pmatrix} \sigma_x^2 & \sigma_{xy} & \sigma_{x\theta} \\ \sigma_{yx} & \sigma_y^2 & \sigma_{y\theta} \\ \sigma_{x\theta} & \sigma_{y\theta} & \sigma_\theta^2 \end{pmatrix}$  Kovarianzmatrix  $\Rightarrow$  Genauigkeit der Lokalität

Labor  
übergang

=> Graphisch als Ellipse (Mahalanobis-Abstand) dargestellt

Beispiel



Gängiger Algorithmus: **Markov-Lokalisierung**:

1.) Vorhersage von  $\hat{x}$  unter Verwendung Odometrieredaten (unge nau Position)

2.) Vorhersage von  $\hat{x}$  mit scan-match (genaue Position)

=> Beschleunigung: Berechnung scan-match durch rekursive Anwendung: Partikelfilter

## ⑧ Routen- / Aktionsplanung

Aufgabe: Geg.: Startposition, i.e.R. aktuelle Fahrzeugposition und Zielposition in Karte.

Ges.: Folge von Aktionen, die das Fahrzeug kollisionsfrei vom Start zum Ziel bewegt.

Unterscheidung: Makronavigation - Graphensuche  
Mikronavigation - Potenzialfeldmethode

### Potenzialfeldmethode

Lage des zylindrischen Roboters soll hier durch Konfiguration  $p(x, y)$  beschreibbar sein.

(Drehung auf der Stelle möglich)

Kraft auf den Roboter ist der Gradient des Potenzialfeldes  $U(p)$ .

$$\vec{F}(p) = -\nabla U(p) = - \begin{pmatrix} \frac{\partial U}{\partial x} \\ \frac{\partial U}{\partial y} \end{pmatrix}$$

Fahrzeug bewegt sich nach der Methode des steilsten Anstiegs zum Ziel.

Ziel hat anziehendes Potenzial. Größtmöglicher Abstand zu Hindernissen durch abstoßendes Potenzial um die Hindernisse herum.